



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

Applied Computer Science

Project Report

Predykcja zainteresowania postami w social media z użyciem metod NLP

Alicja Borek
Dobrawa Rumszewicz
Patryk Kowalczyk

Czerwiec 2026

Spis treści

1	Wprowadzenie	3
2	Dane i wstępna analiza eksploracyjna	4
2.1	Źródło i wybór zbioru danych	4
2.2	Rozkład retweetów i definicja klas	4
2.3	Zmiana zainteresowania w czasie	5
3	Przygotowanie tekstu	7
3.1	Czyszczenie tweetów	7
3.2	Tokenizacja, stopwords i lematyzacja	7
4	Konstruowanie cech i reprezentacja tekstu	9
4.1	Cechy strukturalne i stylistyczne	9
4.2	Analiza sentymentu VADER	12
4.3	Reprezentacja słów: CountVectorizer i TF-IDF	13
4.4	Modelowanie tematów LDA	14
4.5	Łączenie i normalizacja cech	15
5	Budowa i ocena modeli	17
5.1	Podział danych	17
5.2	Porównywane modele	17
5.3	Metryki jakości	18
5.4	Wyniki benchmarku	18
5.5	Szczegółowa ocena modelu końcowego	20
6	Analiza SHAP i dyskusja wyników	21
6.1	Cel analizy SHAP	21
6.2	Globalna ważność cech	21
6.3	Ważność cech dla poszczególnych klas	23
6.4	Interpretacja cech tekstowych	25
6.5	Wyjaśnienia lokalne	25
7	Ograniczenia i odtwarzalność	26
8	Wnioski	27

1 Wprowadzenie

Jedną z podstawowych form reakcji użytkowników serwisu Twitter, obecnie działającego pod nazwą X, było przekazanie dalej cudzego wpisu. W analizowanym zbiorze jest to zapisane jako liczba retweetów. W tym projekcie liczba retweetów została przyjęta jako miara zainteresowania wpisem. Celem jest sprawdzenie, czy z formy i treści wpisu można przewidzieć, czy znalazł się on w grupie tweetów o niskim, średnim albo wysokim zainteresowaniu.

Temat wymaga zbudowania modelu predykcyjnego dla tweetów Donalda Trumpa, wykorzystania reprezentacji słów występujących w tekście oraz przeprowadzenia analizy SHAP. NLP *Natural Language Processing* oznacza przetwarzanie języka naturalnego, czyli przekształcanie tekstu napisanego przez człowieka w postać liczbową, którą może wykorzystywać algorytm uczenia maszynowego.

Głównym pytaniem jest: czy słowa, frazy oraz proste cechy stylistyczne tweetów pozwalają trafnie przewidywać poziom liczby retweetów? Drugie pytanie dotyczy interpretacji modelu: które elementy wpisu najsilniej wpływają na decyzję modelu dotyczącą klasy *Low*, *Medium* albo *High*? Odpowiedź na drugie pytanie uzyskano przy użyciu metody SHAP, czyli *SHapley Additive exPlanations*.

W literaturze dotyczącej konta @realDonaldTrump zwraca się uwagę zarówno na tematykę, jak i na styl wypowiedzi. Clarke i Grieve opisali zmienność stylu tweetów publikowanych na tym koncie i wyróżnili style konwersacyjny, kampanijny, zaangażowany oraz doradczy [4]. Savoy wskazał natomiast na rolę charakterystycznego słownictwa, negatywnego tonu, ocen kategorycznych oraz wzmacniających przymiotników [12]. Te obserwacje uzasadniają wykorzystanie nie tylko pojedynczych słów, ale również cech takich jak liczba wykrzykników, wzmianki o innych użytkownikach, długość tekstu, liczby, czy wskaźniki czytelności. Materiały użyte jako inspiracja do wyboru analizowanych cech, zwracają uwagę na podobne zjawiska stylistyczne, między innymi powtarzalność słów, krótkie zdania, superlatywy oraz wzmianki i hashtagi [5, 17, 7].

2 Dane i wstępna analiza eksploracyjna

2.1 Źródło i wybór zbioru danych

W projekcie wykorzystano zbiór *Trump Tweets* udostępniony na platformie Kaggle [11]. Po rozpakowaniu danych dostępne były dwa pliki: `realdonaldtrump.csv` oraz `trumptweets.csv`. Pierwszy plik zawierał 43 352 rekordy, natomiast drugi 41 122. Porównanie identyfikatorów tweetów wykazało, że oba pliki mają 41 104 wspólnych wpisów. W pliku `realdonaldtrump.csv` znajdowało się dodatkowo 2248 tweetów, a w drugim pliku tylko 18 tweetów nieobecnych w pierwszym. Z tego powodu do dalszej analizy wybrano plik `realdonaldtrump.csv`.

Każdy rekord zawierał identyfikator wpisu, odnośnik, pełną treść, datę publikacji, liczbę retweetów, liczbę polubień, a w części przypadków również informacje o wzmiankach i hashtagach. Kolumna `content` była podstawowym źródłem tekstu. Kolumna `retweets` została wykorzystana do zbudowania zmiennej docelowej. Kolumna `favorites` została wykorzystana wyłącznie w analizie eksploracyjnej i nie znalazła się w końcowej macierzy cech. Włączenie liczby polubień do modelu przewidującego retweety byłoby dużym pominięciem analizy tekstu, ponieważ jak wynika z macierzy korelacji 4.3b kolumny `retweets` i `favorites` są mocno powiązane. Model mógłby wtedy uzyskiwać wysoki wynik dzięki informacjom dostępnym z pierwszych polubień, a nie dzięki analizie języka tweeta.

2.2 Rozkład retweetów i definicja klas


Liczba retweetów ma bardzo nierówny rozkład. Mediana wynosiła 396,5, średnia wynosiła około 6265, a maksymalna wartość osiągała 302 269. Duża różnica między średnią i medianą wskazuje, że niewielka liczba bardzo popularnych tweetów silnie podnosi średnią, co potwierdza wykres 2.1a. Taki rozkład utrudniałby bezpośrednią regresję liczby retweetów, dlatego stworzono klasyfikację trzech poziomów zainteresowania.

Granice klas wyznaczono na podstawie kwantyli rozkładu retweetów. Tweet z nie więcej niż 53 retweetami otrzymał etykietę *Low*. Tweet z liczbą retweetów od 54 do 4558 otrzymał etykietę *Medium*. Tweet z liczbą retweetów większą niż 4558 otrzymał etykietę

High, co przedstawiono w tabeli 2.1b. Zastosowanie dwóch kwantyli, odpowiadających około jednej trzeciej i dwóm trzecim obserwacji, prowadzi do klas o bardzo zbliżonej liczności. Dzięki temu model nie powinien uzyskiwać dobrego wyniku wyłącznie przez wybieranie najczęstszej klasy.

Tabela 2.1: Podstawowe informacje o danych i zadaniu klasyfikacyjnym.

Element	Wartość
Wybrany plik źródłowy	<code>realdonaldtrump.csv</code>
Liczba tweetów	43 352
Liczba klas	3: <i>High</i> , <i>Low</i> , <i>Medium</i>
Granica klasy <i>Low</i>	Maksymalnie 53 retweety
Granica klasy <i>Medium</i>	Od 54 do 4558 retweetów
Granica klasy <i>High</i>	Powyżej 4558 retweetów
Liczba przykładów treningowych	34 681
Liczba przykładów testowych	8671



(a) Rozkład liczby retweetów oraz długości tweetów.

(b) Granice i liczności klas zainteresowania.


Rysunek 2.1: Wykresy z pierwszego etapu analizy eksploracyjnej.

2.3 Zmiana zainteresowania w czasie

W analizie eksploracyjnej data publikacji została przekształcona do formatu daty, a następnie dla każdego roku obliczono medianę liczby retweetów oraz liczbę opublikowanych wpisów. Najwyższą medianę retweetów zaobserwowano w roku 2020, kiedy wynosiła ona 19 279. Z danych widać, że popularność konta konsekwentnie rosła z czasem, co widoczne jest na wykresie 2.2a. Zjawisko to jest istotne interpretacyjnie, ponieważ wysoka liczba retweetów zależy nie tylko od słów użytych w tweecie, lecz również od okresu jego publikacji, bieżących wydarzeń i liczby obserwujących konto.

Zmienna czasu nie została jednak dodana do głównej macierzy cech. Celem projektu było sprawdzenie ile informacji można wyciągnąć z tekstu i jego cech językowych.

Dodanie roku, miesiąca albo godziny mogłoby poprawić wynik predykcyjny, ale osłabiłoby odpowiedź na pytanie, czy sam styl i treść wpisu wyjaśniają zainteresowanie. Z tego powodu analiza czasu została potraktowana jako element rozpoznania danych, a nie jako główne źródło predykcji.



(a) Mediana retweetów i liczba tweetów według roku.

(b) Wczesna korelacja Pearsona między retweetami, długością wpisu i liczbą polubień.

Rysunek 2.2: Analiza zmian zainteresowania w czasie i wstępnych zależności liczbowych.

3 Przygotowanie tekstu

3.1 Czyszczenie tweetów

Tweety zawierają elementy, które mogą utrudniać analizę słów. Należą do nich adresy internetowe, odnośniki do obrazów, emotikony, wielokrotne odstępów i znaki specjalne. W pierwszym etapie każdy tweet został zamieniony na małe litery, a następnie usunięto adresy rozpoczynające się od `http`, `www` oraz odnośniki `pic.twitter.com`. Zachowano cyfry, ponieważ mogą one wskazywać na lata, liczby głosów, wielkości ekonomiczne lub inne fakty, które mają znaczenie dla zainteresowania.


Jeśli chodzi o wzmianki (ang. *mentions*) i hashtagi to postanowiono zachować o nich informację więc zamieniono je do takiego formatu aby znaki `@` i `#` nie zostały potraktowane jak znaki specjalne i usunięte. Wzmianka o koncie jest przekształcana do tokenu w postaci `mentions_nazwa_konta`, na przykład `@CNN` może zostać zapisana jako `mentions_cnn`. Hashtag jest zapisywany jako token `hashtag_nazwa`, na przykład `#MAGA` jako `hashtag_maga`. Takie rozwiązanie zachowuje dwie informacje równocześnie: konkretną nazwę oraz fakt, że nazwa została użyta jako wzmianka albo hashtag. Jest to korzystne dla późniejszej interpretacji SHAP, ponieważ cecha `mentions_foxnews` jest bardziej jednoznaczna niż samo słowo `foxnews`. Dodatkowo usunięto znacznik `rt`, który wskazuje, że wpis jest retweetem.

3.2 Tokenizacja, stopwords i lematyzacja


Po czyszczeniu tekst został podzielony na tokeny. Następnie usunięto angielskie słowa, które występują bardzo często, ale zazwyczaj wnoszą niewiele informacji o temacie, na przykład *the*, *and* lub *of*. Nie zastosowano jednak bezwarunkowego usunięcia wszystkich takich słów. Zachowano zaimki osobowe, przeczenia i czasowniki modalne, między innymi *i*, *you*, *we*, *not*, *never*, *will* oraz *should*. Są to słowa ważne dla stylu, ponieważ mogą sygnalizować zwracanie się do odbiorców, budowanie wspólnoty, deklarowanie pewności albo negowanie stanowiska przeciwnika.

Kolejnym krokiem była lematyzacja przy użyciu narzędzia `WordNetLemmatizer`. Lemat to podstawowa forma słowa używana jako wspólny reprezentant jego odmian (np.

running, *ran* -> *run*). Zastosowanie lematyzacji zmniejsza liczbę odrębnych wariantów słów i pozwala modelowi częściej rozpoznawać podobne znaczenia. Osobno usunięto nazwę konta *realdonaldtrump*, ponieważ pojawia się ona często jako samocytowanie i nie jest interesującym sygnałem językowym.



(a) Chmura słów po przetworzeniu tekstu.



(b) Najczęściej występujące tokeny.

Rysunek 3.1: Wizualne podsumowanie słownictwa po czyszczeniu i lematyzacji.

4 Konstruowanie cech i reprezentacja tekstu

4.1 Cechy strukturalne i stylistyczne

Słowa i frazy są głównym elementem projektu, ale tekst tweetów zawiera również cechy, których nie opisuje sama lista słów. Z tego powodu obliczono 45 dodatkowych cech liczbowych. Wykorzystano liczbę wykrzykników, znaków zapytania, słów zapisanych wielkimi literami, słów, zdań i znaków. Dodano również liczbę hashtagów, wzmianek, adresów internetowych i odnośników do mediów. Wielkie litery są na przykład wykorzystywane jako podkreślenie emocji.

Cechy strukturalne, takie jak liczba wykrzykników, hashtagów czy wzmianek, zostały obliczone na podstawie oryginalnej kolumny `content`, a nie na kolumnie `processed_content` przygotowanej w etapie czyszczenia tekstu. Wynika to z tego, że czyszczenie usuwa adresy internetowe oraz przekształca znaki `@` i `#` do osobnych tokenów, więc liczenie tych elementów po czyszczeniu byłoby niemożliwe albo niepoprawne. Cechy oparte na konkretnym słownictwie, na przykład zaimkach albo słowach wzmacniających, zostały natomiast obliczone na kolumnie `processed_content`, ponieważ tam tekst jest już ujednolicony pod względem wielkości liter i podziału na tokeny.

Aby porównać krótkie i długie tweety, obliczono także wskaźniki względne. Przykładowo `exclamation_per_word` oznacza liczbę wykrzykników podzieloną przez liczbę słów powiększoną o jeden. Cechy `ends_with_exclamation` oraz `ends_with_question` wskazują, czy tweet kończy się odpowiednio wykrzyknikiem albo pytajnikiem. Wskaźnik `max_exclamation_run` mierzy najdłuższy ciąg kolejnych wykrzykników, a `shouting_index` określa udział wielkich liter w całym wpisie.

Osobna grupa cech została zbudowana na podstawie list z określonym typem słownictwa. Obliczono liczbę zaimków pierwszej osoby liczby pojedynczej i mnogiej, liczbę zwrotów w drugiej osobie, czasowników modalnych i przeczeń. Obliczono również liczbę słów wzmacniających, słów wyrażających pewność, superlatywów oraz wyraźnie negatywnych określeń. Cechy te nie zastępują reprezentacji słów, ale umożliwiają modelowi uchwycenie szerszych właściwości stylu, na przykład skłonności do używania kategoriycznych ocen albo bezpośrednich zwrotów do odbiorcy.

Każda z czterech list słownikowych (*emphatic_word_count*, *certainty_word_count*, *superlative_word_count*, *negative_emphatic_word_count*) została zbudowana w dwóch warstwach. Pierwszą warstwę stanowi ogólny angielski słownik danego typu słownictwa, na przykład typowe wzmacniacze (*extremely*, *absolutely*, *incredibly*) albo typowe superlatywy (*best*, *greatest*, *worst*). Drugą warstwą jest zbiór słów charakterystycznych konkretnie dla stylu wypowiedzi z analizowanego konta, dodany do list ogólnych, na przykład *tremendous*, *fake*, *rigged* czy *witchhunt*. Niektóre słowa z tej drugiej warstwy, takie jak *tremendous* czy *incredible*, celowo należą jednocześnie do więcej niż jednej listy, ponieważ w analizowanych tweetach pełnią funkcję zarówno wzmacniacza, jak i superlatywu. Rozszerzenie ogólnych list o słownictwo specyficzne dla konta pozwala cechom dokładniej odzwierciedlać rzeczywisty, powtarzalny zestaw słów używanych przez autora, a nie wyłącznie ogólny rejestr języka angielskiego.

W projekcie uwzględniono również długość przeciętnego słowa, długość przeciętnego zdania, wskaźnik czytelności Flesch Reading Ease, poziom Flesch–Kincaid Grade, współczynnik powtórzeń słów oraz Type-Token Ratio. Type-Token Ratio jest ilorazem liczby różnych słów i liczby wszystkich słów. Wysoka wartość oznacza większą różnorodność słownictwa, a niska wartość wskazuje na powtarzalność. Cechy czytelności należy interpretować ostrożnie, ponieważ zostały pierwotnie opracowane dla dłuższych tekstów, podczas gdy tweet jest bardzo krótką formą wypowiedzi.


Jak stworzone cechy są powiązane z liczbą retweetów, pokazuje wykres 4.3b, a zwłaszcza pierwsza kolumna którą podkreślono. Widać, że niektóre cechy mają wyraźną korelację z liczbą retweetów.

Tabela 4.1: Grupy cech liczbowych wykorzystanych w końcowej macierzy danych.


Grupa	Zastosowane kolumny
Interpunkcja i długość	exclamation_count, question_count, capslock_words_count, word_count, sentence_count, char_count.
Elementy platformy	hashtag_count, mention_count, has_url, has_media_link, url_count.
Intensywność zapisu	exclamation_per_word, question_per_word, ends_with_exclamation, ends_with_question, max_exclamation_run, shouting_index.
Zaimdek i retoryka	first_person_singular_count, first_person_plural_count, second_person_count, modal_count, negation_count, emphatic_word_count, certainty_word_count, superlative_word_count, negative_emphatic_word_count.
Czytelność i słownictwo	avg_word_length, avg_sentence_length, flesch_reading_ease, flesch_kincaid_grade, repetition_ratio, lexical_diversity_ttr.
Sentyment	sent_vader_neg, sent_vader_neu, sent_vader_pos, sent_vader_compound.
Liczby w tekście	has_number, number_token_count, has_year_mention, has_large_number.
Tematy	topic_lda_1, topic_lda_2, topic_lda_3, topic_lda_4, topic_lda_5.

W czasie analizy stwierdzono, że 13 118 tweetów, czyli około 30,3%, zawiera co najmniej jedną liczbę. Około 3,1% wpisów (1339) zawiera rok w postaci czterech cyfr, a około 0,2% (93) zawiera inną liczbę co najmniej czterocyfrową. Takie elementy mogą opisywać informacje dotyczące wyborów, dat, wyników lub wartości ekonomicznych, dlatego zostały zachowane w zbiorze cech.

Cecha `has_year_mention` jest ustawiana na 1, gdy w tekście pojawia się czterocyfrowa liczba zaczynająca się od 19 albo 20, a więc liczba, którą można odczytać jako rok. Cecha `has_large_number` jest natomiast ustawiana na 1, gdy w tekście pojawia się liczba złożona z co najmniej czterech cyfr, która jednocześnie nie spełnia wzorca roku. Rozdzielenie tych dwóch cech pozwala modelowi odróżnić odwołania do dat od innych dużych liczb, na przykład wyników głosowania albo wartości ekonomicznych.



(a) Rozkłady cech stylistycznych.



(b) Związek liczb w tekście z logarytmem liczby retweetów.

Rysunek 4.1: Wykresy z etapu tworzenia cech.


4.2 Analiza sentymentu VADER

Dla każdego wpisu obliczono wynik sentymentu metodą VADER, czyli *Valence Aware Dictionary and sEntiment Reasoner*. Jest to słownikowo-regułowa metoda przygotowana do tekstów z mediów społecznościowych [8]. Zwraca ona cztery podstawowe wartości: udział tonu negatywnego, neutralnego i pozytywnego oraz wynik złożony `compound` w przybliżonym zakresie od -1 do 1 . Wartość ujemna sugeruje przewagę tonu negatywnego, dodatnia przewagę tonu pozytywnego, a wartość bliska zero wskazuje na ton neutralny.

Do obliczania sentymentu wykorzystano oryginalną treść tweetów po usunięciu adresów internetowych oraz samych znaków `@` i `#` wraz z następującym po nich słowem,

ponieważ nazwy kont i hashtagów nie powinny same z siebie wpływać na wykryty sentyment. Zachowano natomiast interpunkcję, wielkie litery i emotikony, ponieważ VADER potrafi wykorzystywać te sygnały. Wartość `sentiment_intensity`, równa wartości bezwzględnej wyniku `compound`, została utworzona do analizy pomocniczej. Do końcowej macierzy modelu weszły cztery podstawowe wyniki VADER: negatywny, neutralny, pozytywny i złożony.

Na potrzeby wykresów i analizy pomocniczej wynik `compound` został dodatkowo przekształcony w kategorię opisową `sentiment_category`. Tweet z wynikiem `compound` co najmniej równym 0,05 otrzymał etykietę Positive, tweet z wynikiem nie większym niż -0,05 otrzymał etykietę Negative, a pozostałe przypadki, leżące blisko zera, otrzymały etykietę Neutral. Są to standardowo przyjęte dla metody VADER granice progowe. Kategoria ta nie weszła do końcowej macierzy cech modelu, ponieważ informacje o sentymencie w pełniejszej, ciągłej formie przenoszą już cztery wyniki liczbowe VADER.



Rysunek 4.2: Rozkład kategorii sentymentu, rozkład wyniku złożonego VADER oraz logarytm liczby retweetów w zależności od sentymentu.

4.3 Reprezentacja słów: CountVectorizer i TF-IDF

Model klasyfikacyjny nie może bezpośrednio operować na ciągu znaków, dlatego tekst zamieniono na wektor liczb. Pierwszą zastosowaną reprezentacją był CountVectorizer. Dla każdego tweetu tworzy on wiersz macierzy, a dla każdego słowa lub frazy tworzy kolumnę. Wartość w komórce oznacza liczbę wystąpień danego słowa albo frazy w konkretnym tweecie. Taka reprezentacja jest nazywana Bag of Words, ponieważ zachowuje informacje o występowaniu słów, lecz nie zachowuje kolejności w zdaniu [19].

Drugą reprezentacją był TF-IDF, czyli *Term Frequency-Inverse Document Frequency*. Pierwsza część tego skrótu, *term frequency*, opisuje częstość danego terminu w kon-

kretnym dokumencie. Druga część, *inverse document frequency*, obniża znaczenie słów występujących w bardzo wielu dokumentach. Matematycznie jest to zapisane jako [18]:

$$\text{TFIDF}(t, d) = \text{TF}(t, d) \cdot \log \left(\frac{N}{\text{DF}(t) + 1} \right),$$


gdzie t oznacza termin, d oznacza tweeta, N oznacza liczbę tweetów, a $\text{DF}(t)$ oznacza liczbę tweetów zawierających termin t . Dzięki temu często występujące słowa o małej wartości rozróżniającej otrzymują niższą wagę, a słowa charakterystyczne dla mniejszej części wpisów otrzymują wyższą wagę [16].

W obu reprezentacjach zastosowano jednoelementowe i dwuelementowe n-gramy. Jednoelementowy n-gram to pojedyncze słowo, na przykład *great*. Dwuelementowy n-gram, nazywany bigramem, to para kolejnych słów, na przykład *fake news* albo *thank you*. Uwzględnienie bigramów jest istotne, ponieważ znaczenie frazy nie zawsze wynika z sumy znaczeń pojedynczych słów. Słownik ograniczono do 10 000 cech tekstowych. Dodatkowo odrzucono terminy występujące w mniej niż pięciu tweetach oraz terminy obecne w ponad 95% tweetów. Otrzymano dwie macierze tekstowe o wymiarze 43 352 na 10 000.

4.4 Modelowanie tematów LDA

W projekcie zastosowano również modelowanie tematów metodą LDA, czyli *Latent Dirichlet Allocation* [2]. Metoda ta zakłada, że dokument może łączyć kilka ukrytych tematów, a każdy temat jest opisywany przez rozkład słów. Zasadniczo algorytm LDA zakłada, że dokumenty zostały wygenerowane poprzez losowe próbkowanie tematów sprzed utworzenia dokumentu i próbuje dokonać inżynierii wstecznej tego próbkowania, co przedstawione jest na stronie IBM [10].

Model LDA został dopasowany do surowych zliczeń słów z *CountVectorizer*, ponieważ LDA operuje na reprezentacji bag of words. Ustalono liczbę pięciu tematów. Dla każdego tweetu otrzymano pięć liczb `topic_lda_1`-`topic_lda_5`, które opisują stopień przypisania wpisu do poszczególnych tematów. Wśród ważnych słów tematów pojawiły się między innymi *country*, *china*, *thank you*, *democrat*, *fake news* oraz nazwy użytkowników 4.3a. Te cechy nie zastępują tekstowej reprezentacji TF-IDF, ale dodają dodatkową informację o dominujących obszarach treści.



Rysunek 4.3: Wizualizacja tematów oraz współzależności cech numerycznych.

4.5 Łączenie i normalizacja cech

Cechy tekstowe i cechy liczbowe mają różne skale. Przykładowo liczba znaków może mieć wartość większą niż 100, wskaźnik sentymentu złożonego mieści się w pobliżu przedziału od -1 do 1 , a cecha binarna ma wyłącznie wartości 0 i 1 . Aby żadna cecha nie dominowała wyłącznie z powodu swojej skali, wszystkie 45 cech liczbowych zostało przeskalowane metodą `StandardScaler`. Po standaryzacji każda cecha ma średnią równą zero i odchylenie standardowe równe jeden w zbiorze użytym do dopasowania skalera.

Następnie połączono kolumny tekstowe z kolumnami liczbowymi. Otrzymano dwie końcowe rzadkie macierze:

`X_tfidf_features.npz` oraz `X_count_features.npz`.

Każda z nich ma 10 045 kolumn, ponieważ zawiera 10 000 cech tekstowych i 45 cech liczbowych. Macierz rzadka przechowuje przede wszystkim wartości różne od zera. Jest to ważne, ponieważ pojedynczy tweet nie zawiera większości słów obecnych w słowniku, a zapisywanie wszystkich zer byłoby bardzo nieefektywne pamięciowo.

Na tym etapie obliczono również logarytm liczby retweetów, `log_retweets`, i zapisano go w pełnym pliku `df_with_features.csv` razem z pozostałymi kolumnami. Kolumna ta nie została jednak włączona do żadnej z dwóch macierzy cech użytych do trenowania modeli klasyfikacyjnych. Liczba retweetów jest bowiem podstawą zmiennej docelowej `engagement_level`, więc dodanie jej logarytmu do cech byłoby bezpośrednim wyciekaniem informacji o etykiecie do zbioru danych wejściowych. Kolumna ta

została zachowana wyłącznie jako materiał pomocniczy do ewentualnych przyszłych eksperymentów regresyjnych, w których liczba retweetów byłaby przewidywana jako wartość liczbowa, a nie jako klasa.

5 Budowa i ocena modeli

5.1 Podział danych

Dane zostały podzielone na zbiór treningowy i testowy w proporcji 80% do 20%. Zbiór treningowy zawierał 34 681 tweetów, a testowy 8671. Podział był stratyfikowany, co oznacza, że proporcje klas *High*, *Low* i *Medium* zostały zachowane w obu częściach danych.

Etykiety tekstowe zostały technicznie zakodowane jako liczby. Zastosowany LabelEncoder [9] uporządkował je alfabetycznie, dlatego w aktualnym uruchomieniu kod 0 oznaczał klasę *High*, kod 1 klasę *Low*, a kod 2 klasę *Medium*. To kodowanie nie oznacza, że klasa *High* jest mniejsza od *Low*. Jest to wyłącznie techniczna reprezentacja kategorii.

5.2 Porównywane modele

Pierwszym punktem odniesienia był DummyClassifier ze strategią *most frequent*. Nie analizuje on żadnych cech i zawsze przewiduje klasę najczęściej występującą w zbiorze treningowym. Jego wynik pokazuje minimalny poziom, który powinny wyraźnie przekroczyć modele wykorzystujące tekst. [6]

Następnie przetestowano regresję logistyczną. Model oblicza dla każdej klasy wynik zależny od ważonej sumy cech, a następnie wybiera klasę o największym prawdopodobieństwie. Jest to model liniowy, co oznacza, że wpływ pojedynczej cechy jest opisany przez współczynnik. Ta właściwość ułatwia późniejszą interpretację SHAP. [20]

Kolejnym modelem był liniowy SVM (Support Vector Machine). Model SVM poszukuje granic rozdzielających klasy w przestrzeni cech. [15] W projekcie porównano regresję logistyczną i liniowy SVM zarówno dla reprezentacji TF-IDF, jak i dla prostych zliczeń CountVectorizer.

Ostatnią grupą modeli były klasyfikatory XGBoost (eXtreme Gradient Boosting). XGBoost jest metodą wzmacniania drzew decyzyjnych. Kolejne drzewa są budowane tak, aby poprawiać błędy poprzednich drzew. [21] W projekcie zastosowano 250 drzew o maksymalnej głębokości 4, szybkość uczenia równą 0,05 oraz algorytm `hist`. XGBoost

jest modelem nieliniowym, dlatego stanowi porównanie dla modeli liniowych.

5.3 Metryki jakości

Jakość klasyfikatorów porównano za pomocą kilku metryk. Accuracy, czyli dokładność, jest odsetkiem poprawnie sklasyfikowanych tweetów. Balanced accuracy, czyli zrównoważona dokładność, jest średnią czułości obliczoną osobno dla każdej klasy. Metryka ta jest szczególnie przydatna, gdy klasy mają różną licznosc. [1]

Dodatkowo wykorzystano macro F1 i weighted F1. Miara F1 łączy precyzję i czułość. Precyzja odpowiada na pytanie, jaka część tweetów przypisanych przez model do danej klasy rzeczywiście do niej należy. Czułość odpowiada na pytanie, jaką część prawdziwych przykładów tej klasy model odnalazł. Macro F1 oblicza wynik F1 dla każdej klasy oddzielnie, a następnie traktuje wszystkie klasy równorzędnie. Weighted F1 również liczy wynik dla każdej klasy, ale nadaje większą wagę klasom liczniejszym. W tym projekcie jako główną metrykę wyboru modelu przyjęto macro F1, ponieważ zależało nam na porównywalnej jakości dla klas *High*, *Low* i *Medium*.

5.4 Wyniki benchmarku

Tabela 5.1 przedstawia wyniki uzyskane na zbiorze testowym. Najlepszy wynik macro F1, równy 0,818, uzyskała regresja logistyczna wykorzystująca TF-IDF oraz cechy liczbowe. Ten sam model osiągnął accuracy równą 0,818 i balanced accuracy równą 0,818. Wyniki regresji logistycznej i liniowego SVM dla TF-IDF były bardzo zbliżone, ale regresja logistyczna była nieznacznie lepsza i została wybrana jako model końcowy.


Tabela 5.1: Wyniki modeli na zbiorze testowym. Najwyższa wartość macro F1 została wyróżniona pogrubieniem.

Model	Accuracy	Balanced accuracy	Macro F1	Czas uczenia [s]
DummyClassifier, najczęstsza klasa	0,335	0,333	0,167	0,0
Regresja logistyczna, TF-IDF + cechy liczbowe	0,818	0,818	0,818	45,2
Liniowy SVM, TF-IDF + cechy liczbowe	0,814	0,814	0,813	57,4
Regresja logistyczna, Count + cechy liczbowe	0,812	0,812	0,812	52,9
Liniowy SVM, Count + cechy liczbowe	0,786	0,786	0,785	29,8
XGBoost, TF-IDF + cechy liczbowe	0,794	0,794	0,793	79,4
XGBoost, Count + cechy liczbowe	0,793	0,793	0,792	8,2

Różnica między najlepszym modelem a DummyClassifier jest bardzo duża. Model bazowy uzyskał macro F1 równe 0,167, ponieważ praktycznie zawsze wskazywał tę samą klasę. Reprezentacja TF-IDF okazała się lepsza od prostych zliczeń słów zarówno dla regresji logistycznej, jak i dla liniowego SVM. Oznacza to, że ważenie rzadziej występujących, bardziej charakterystycznych terminów było tutaj użyteczne.



(a) Porównanie metryk modeli.



(b) Czas uczenia modeli.

Rysunek 5.1: Porównanie jakości i kosztu obliczeniowego modeli.


5.5 Szczegółowa ocena modelu końcowego

Dla wybranego modelu obliczono raport klasyfikacji. Klasa *High* została rozpoznana najlepiej, z wynikiem F1 równym 0,888. Klasa *Low* uzyskała F1 równe 0,826. Najtrudniejsza była klasa *Medium*, dla której F1 wyniosło 0,739. Jest to intuicyjne, ponieważ klasa środkowa leży między dwiema pozostałymi klasami i może zawierać wpisy podobne zarówno do tweetów o niskim, jak i wysokim zainteresowaniu.

Tabela 5.2: Raport klasyfikacji dla regresji logistycznej z reprezentacją TF-IDF i cechami liczbowymi.




Klasa	Precyzja	Czułość	F1	Liczba tweetów
High	0,899	0,878	0,888	2890
Low	0,815	0,838	0,826	2904
Medium	0,740	0,737	0,739	2877
Średnia macro	0,818	0,818	0,818	8671

Normalized Confusion Matrix — Logistic Regression - TF-IDF + numeric



(a) Macierz pomyłek modelu końcowego.

Normalized Confusion Matrices — Top Models



(b) Macierze pomyłek trzech najlepszych modeli.

Rysunek 5.2: Ocena błędów klasyfikacji.

6 Analiza SHAP i dyskusja wyników

6.1 Cel analizy SHAP

Wysoki wynik modelu nie odpowiada jeszcze na pytanie, dlaczego model podjął określoną decyzję. Analiza SHAP (SHapley Additive exPlanations) służy do przypisania wkładu poszczególnych cech do wyniku modelu [14].

Dla pojedynczego tweeta wynik modelu dla wybranej klasy można przybliżyć równaniem [13]:

$$f(\mathbf{x}) \approx \phi_0 + \sum_{j=1}^p \phi_j,$$

gdzie $f(\mathbf{x})$ jest wynikiem modelu dla tweetu $\mathbf{x}$, ϕ_0 jest wynikiem bazowym, p oznacza liczbę cech, a ϕ_j jest wkładem j -tej cechy. Dodatnia wartość SHAP dla klasy *High* oznacza, że dana cecha przesuwaa wynik modelu w kierunku tej klasy. Ujemna wartość oznacza, że przesuwaa wynik w przeciwną stronę. [13]

Ponieważ modelem końcowym była regresja logistyczna, zastosowano `shap.LinearExplainer`. Ten explainer jest dostosowany do modeli liniowych. Analizie poddano losową próbę 350 tweetów ze zbioru testowego. Tło referencyjne zawierało 1000 przykładów treningowych, jednak mechanizm maskujący SHAP użył podpróby 100 przykładów jako kompromisu pomiędzy stabilnością wyniku a kosztem obliczeń. Dla każdej z 350 obserwacji obliczono wkład 10 045 cech dla trzech klas, co dało tablicę o wymiarze (350, 10045, 3).

6.2 Globalna ważność cech


Globalna ważność cechy została obliczona jako średnia wartość bezwzględna SHAP, uśredniona po analizowanych tweetach i klasach. Wysoka wartość oznacza, że cecha często i silnie zmienia decyzje modelu, niezależnie od kierunku tego wpływu. Dane zostały przedstawione w tabeli 6.1 oraz wykresie 6.1a. Najważniejszą cechą globalną była liczba słów `word_count`. Następne pozycje zajęły liczba wzmianek `mention_count`, wskaźnik czytelności Flesch Reading Ease, średnia długość zdania, wynik Flesch-Kincaid Grade, liczba znaków, udział trzeciego tematu LDA, obecność odnośnika do medium

oraz liczba wykrzykników.


Tabela 6.1: Najważniejsze cechy według średniej wartości bezwzględnej SHAP.

Cecha	Średnia wartość SHAP
word_count	0,531
mention_count	0,494
flesch_reading_ease	0,457
avg_sentence_length	0,320
flesch_kincaid_grade	0,293
char_count	0,275
topic_lda_3	0,261
has_media_link	0,246
exclamation_count	0,235
max_exclamation_run	0,205

W całej analizie cechy ręcznie skonstruowane, nazywane dalej cechami inżynierskimi, odpowiadały za około 65,6% sumy globalnej ważności SHAP. Tekstowe jedno- i dwuwyrazowe n-gramy odpowiadały za około 34,4%. 6.1b pokazuje ten udział. Nie oznacza to, że reprezentacja słów była niepotrzebna. Przeciwnie, porównanie modeli wykazało, że TF-IDF poprawia jakość klasyfikacji. Wynik SHAP pokazuje natomiast, że po połączeniu obu rodzajów danych model wykorzystywał także silne i łatwo mierzalne sygnały stylistyczne, takie jak długość wpisu, liczba wzmianek oraz obecność mediów.



(a) Globalna ważność cech SHAP.



(b) Udział cech tekstowych i inżynierskich w ważności SHAP.

Rysunek 6.1: Globalna interpretacja modelu końcowego.

6.3 Ważność cech dla poszczególnych klas


Dla klasy *High* największe średnie wartości bezwzględne SHAP miały: liczba wzmianek, czytelność Flesch Reading Ease, liczba słów, poziom Flesch-Kincaid Grade, liczba znaków, trzeci temat LDA, liczba wykrzykników, obecność medium i długość ciągu wykrzykników. 6.2a

Dla klasy *Low* szczególnie ważne były liczba słów, liczba wzmianek, czytelność, długość zdania oraz obecność linku do medium. 6.2b


Dla klasy *Medium* dominowały średnia długość zdania, obecność adresu internetowego, liczba wykrzykników w stosunku do długości tweetu oraz długość tekstu. 6.2c

Należy tutaj rozróżnić dwie informacje. Średnia wartość bezwzględna SHAP mówi, że cecha jest ważna. Średnia wartość ze znakiem mówi, czy w analizowanej próbce cecha przeciętnie przesuwala wynik w stronę danej klasy, czy od niej oddalała. Jeżeli średnia wartość ze znakiem jest bliska zeru, nie oznacza to braku znaczenia. Może oznaczać, że dla części tweetów cecha zwiększa wynik klasy, a dla innych go zmniejsza.


6.3




Rysunek 6.2: Najważniejsze cechy |SHAP| dla każdej klasy zainteresowania.




Rysunek 6.3: Najważniejsze cechy SHAP ze znakiem dla każdej klasy zainteresowania.




(a) Klasa High.




(b) Klasa High.




(c) Klasa Low.



(d) Klasa Low.



(e) Klasa Medium.



(f) Klasa Medium.


6.4 Interpretacja cech tekstowych

Wśród tekstowych n-gramów zauważalną wagę miały między innymi `mentions_realdonaldtrump`, `mentions_foxnews` oraz słowo `thanks`.

Szczególnie istotne jest zachowanie wzmianki w postaci `mentions_nazwa`. Gdyby usunąć wyłącznie znak `@`, model widziałby na przykład zwykły token `cnn`. Dzięki prefiksowi `mentions_` można odróżnić nazwę używaną jako wzmianka od potencjalnego zwykłego słowa oraz łatwiej analizować decyzje SHAP. Wynik ten wspiera decyzję o zachowaniu pełnych wzmianek w tekście poddawanych wektoryzacji.

6.5 Wyjaśnienia lokalne

Poza analizą globalną przygotowano wyjaśnienia lokalne, czyli wyjaśnienia pojedynczych tweetów. Dla każdego przykładu wykres 6.5 pokazuje cechy najsilniej przesuwające wynik modelu w kierunku przewidzianej klasy oraz cechy działające w przeciwnym kierunku.



Rysunek 6.5: Przykładowe lokalne wyjaśnienia SHAP.

7 Ograniczenia i odtwarzalność

Najważniejszym ograniczeniem obecnej implementacji jest moment przygotowania cech. CountVectorizer, TF-IDF, StandardScaler oraz model LDA zostały dopasowane do pełnego zbioru danych przed wykonaniem podziału na zbiór treningowy i testowy. Oznacza to, że słownik słów, wagi TF-IDF, parametry skalowania i tematy LDA zostały obliczone z wykorzystaniem również tweetów, które później znalazły się w zbiorze testowym. Czyli mamy przeciek danych, ponieważ część informacji o rozkładzie testowym trafia do etapu przygotowania danych.

Przeciek nie przekazuje modelowi bezpośrednio poprawnych etykiet klas, ale może nieznacznie zawyżać raportowane wyniki. W projekcie przyjęto to uproszczenie ze względu na przejrzystą organizację notebooków i zapis pełnych macierzy cech do plików. W wersji stricte produkcyjnej należałoby najpierw podzielić surowe dane na zbiór treningowy i testowy, następnie dopasować wszystkie przekształcenia wyłącznie na danych treningowych, a później zastosować je do danych testowych.

Drugim ograniczeniem jest to, że liczba retweetów zależy od wielu czynników nieobecnych w macierzy cech. Należą do nich czas publikacji, liczba obserwujących konto w danym okresie, bieżące wydarzenia polityczne, ekspozycja medialna i działanie mechanizmów platformy.

Aby odtworzyć wyniki, należy pobrać dane ze strony Kaggle, umieścić pliki w katalogu `data/raw`, utworzyć środowisko wirtualne i zainstalować wymagane biblioteki. Następnie notebooki należy uruchomić w kolejności: `01_EDA.ipynb`, `02_preprocessing.ipynb`, `03_features.ipynb`, `04_models.ipynb` oraz `05_shap.ipynb`. Notebooki zapisują przetworzone dane, macierze cech, model końcowy oraz wyniki analizy w odpowiednich katalogach projektu.

Całość kodu wraz z dokumentacją przygotowaną w latex'u oraz wszystkimi grafikami jest dostępna na GitHubie pod adresem [3].

8 Wnioski

W projekcie zbudowano system klasyfikujący tweety do trzech poziomów zainteresowania mierzonego liczbą retweetów. Podstawą systemu była reprezentacja tekstu za pomocą TF-IDF i CountVectorizer, rozszerzona o 45 cech opisujących formę i styl wypowiedzi. Najlepszy rezultat uzyskała regresja logistyczna pracująca na reprezentacji TF-IDF połączonej z cechami liczbowymi. Model osiągnął macro F1 równe 0,818 oraz accuracy równe 0,818 na wydzielonym zbiorze testowym. Wynik ten był wyraźnie lepszy od klasyfikatora bazowego, który zawsze wybierał najczęstszą klasę.

Porównanie modeli wskazało, że dla dużej, rzadkiej macierzy słów dobrze sprawdzają się modele liniowe. TF-IDF okazał się lepszy niż proste zliczenia słów, co sugeruje, że ważenie terminów charakterystycznych dla mniejszej części tweetów jest w tym zadaniu przydatne. Analiza SHAP pokazała, że model korzysta nie tylko z pojedynczych słów i bigramów, ale również z długości wpisu, liczby wzmianek, cech czytelności, obecności linków do mediów, interpunkcji i tematów LDA.

Analiza SHAP umożliwiła przedstawienie tych zależności w sposób zrozumiały i pozwoliła przejść od samego wyniku klasyfikacji do dyskusji o cechach, które model rzeczywiście wykorzystuje.

Bibliografia

- [1] *Balanced accuracy for Imbalanced binary AND Multi-class Medical Image Classification*. Artykuł na stronie Medium wyjaśniający działanie zrównoważonej dokładności. URL: <https://medium.com/@ayeshagunarathne/balanced-accuracy-for-imbalanced-binary-multi-class-medical-image-classification-80d490161d5c> (term. wiz. 20.06.2026).
- [2] David M. Blei, Andrew Y. Ng i Michael I. Jordan. „Latent Dirichlet Allocation”. W: *Journal of Machine Learning Research* 3 (2003), s. 993–1022. DOI: <https://dl.acm.org/doi/10.5555/944919.944937>. URL: <https://www.jmlr.org/papers/volume3/blei03a/blei03a.pdf>.
- [3] Kowalczyk Borek Dobrawa. *Social Media Engagement Prediction*. Repozytorium projektu na platformie GitHub. 2026. URL: <https://github.com/xalixja/social-media-engagement-prediction> (term. wiz. 21.06.2026).
- [4] Isobelle Clarke i Jack Grieve. „Stylistic variation on the Donald Trump Twitter account: A linguistic analysis of tweets posted between 2009 and 2018”. W: *PLOS ONE* 14.9 (2019), e0222062. DOI: [10.1371/journal.pone.0222062](https://doi.org/10.1371/journal.pone.0222062).
- [5] *Donald Trump’s Language Use on Twitter: What Does Our Analysis Say?* Text Inspector. 2022. URL: <https://textinspector.com/donald-trump-tweet-analysis/> (term. wiz. 20.06.2026).
- [6] *Dummy Classifiers using Sklearn - ML*. Artykuł na stronie GeeksforGeeks wyjaśniający działanie klasyfikatora DummyClassifier w bibliotece scikit-learn. URL: <https://www.geeksforgeeks.org/machine-learning/ml-dummy-classifiers-using-sklearn/> (term. wiz. 20.06.2026).
- [7] K. C. Healy. *The Best Words: How to Use Trump’s Tweets to Improve Your Writing*. 2018. URL: <https://medium.com/@KristenCHealy/the-best-words-how-to-use-trump-s-tweets-to-improve-your-writing-7b2cfe4b5057> (term. wiz. 20.06.2026).
- [8] Clayton J. Hutto i Eric Gilbert. „VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text”. W: *Proceedings of the International AAAI Conference on Web and Social Media*. T. 8. 1. 2014, s. 216–225. DOI: [10.1609/icwsm.v8i1.14550](https://doi.org/10.1609/icwsm.v8i1.14550).

- [9] *Label Encoding in Python*. Artykuł na stronie GeeksforGeeks wyjaśniający działanie klasyfikatora LabelEncoder w bibliotece scikit-learn. URL: <https://www.geeksforgeeks.org/machine-learning/ml-label-encoding-of-datasets-in-python/> (term. wiz. 20.06.2026).
- [10] *Latent Dirichlet Allocation*. Artykuł na stronie IBM wyjaśniający metodę LDA. URL: <https://www.ibm.com/think/topics/latent-dirichlet-allocation> (term. wiz. 20.06.2026).
- [11] Austin Reese. *Trump Tweets*. Zbiór danych w serwisie Kaggle. 2026. URL: <https://www.kaggle.com/datasets/austinreese/trump-tweets> (term. wiz. 20.06.2026).
- [12] Jacques Savoy. „Stylometric Analysis of Trump’s Tweets”. W: *Digital Scholarship in the Humanities* (2022). DOI: 10.1093/llc/fqab046.
- [13] SHAP. Strona internetowa autora książki "Interpretable Machine Learning" poświęcona metodzie SHAP. URL: <https://christophm.github.io/interpretable-ml-book/shap.html> (term. wiz. 20.06.2026).
- [14] *SHAP : A Comprehensive Guide to SHapley Additive exPlanations*. Artykuł na stronie GeeksforGeeks wyjaśniający działanie SHAP. URL: <https://www.geeksforgeeks.org/machine-learning/shap-a-comprehensive-guide-to-shapley-additive-explanations/> (term. wiz. 20.06.2026).
- [15] *Support Vector Machine (SVM) Algorithm*. Artykuł na stronie GeeksforGeeks wyjaśniający działanie SVM (Support Vector Machine). URL: <https://www.geeksforgeeks.org/machine-learning/support-vector-machine-algorithm/> (term. wiz. 20.06.2026).
- [16] *TFIDF*. Artykuł na Wikipedii wyjaśniający metodę TF-IDF. URL: <https://pl.wikipedia.org/wiki/TFIDF> (term. wiz. 20.06.2026).
- [17] *The math behind Trump's tweets*. The Conversation. 2018. URL: <https://theconversation.com/the-math-behind-trumps-tweets-100314> (term. wiz. 20.06.2026).
- [18] *Understanding TF-IDF (Term Frequency-Inverse Document Frequency)*. Artykuł na stronie GeeksforGeeks wyjaśniający metodę TF-IDF wraz z równaniem. URL: <https://www.geeksforgeeks.org/machine-learning/understanding-tf-idf-term-frequency-inverse-document-frequency/> (term. wiz. 20.06.2026).
- [19] *Using CountVectorizer to Extracting Features from Text*. Artykuł na stronie GeeksforGeeks wyjaśniający metodę CountVectorizer. URL: <https://www.geeksforgeeks.org/nlp/using-countvectorizer-to-extracting-features-from-text/> (term. wiz. 20.06.2026).

- [20] *What is logistic regression?* Artykuł na stronie IBM wyjaśniający działanie regresji logistycznej. URL: <https://www.ibm.com/think/topics/logistic-regression> (term. wiz. 20.06.2026).
- [21] *What is XGBoost?* Artykuł na stronie IBM wyjaśniający działanie XGBoost (eXtreme Gradient Boosting). URL: <https://www.ibm.com/think/topics/xgboost> (term. wiz. 20.06.2026).